



Universidad de Castilla-La Mancha
Escuela Superior de Ingeniería Informática de Albacete

Trabajo Fin de Grado
Grado en Ingeniería Informática
Computación

**Especificación de formato y desarrollo de
herramientas para el procesamiento de
curriculum vitae en el ámbito académico
universitario**

Carlos Martínez Jaén

Julio, 2026

TRABAJO FIN DE GRADO
Grado en Ingeniería Informática
Computación

**Especificación de formato y desarrollo de
herramientas para el procesamiento de
curriculum vitae en el ámbito académico
universitario**

Autor: Carlos Martínez Jaén

Director: Luis De La Ossa Jiménez

Codirector: José Antonio Gámez Martín

Julio, 2026

*Aquí va la dedicatoria que cada cual
quiera escribir. El ancho se controla
manualmente*

Declaración de autoría

Yo, ... , con DNI ... , declaro que soy el único autor del trabajo fin de grado titulado “ ... ”, que el citado trabajo no infringe las leyes en vigor sobre propiedad intelectual, y que todo el material no original contenido en dicho trabajo está apropiadamente atribuido a sus legítimos autores.

Albacete, a ... de ... de 20 ...

Fdo.: Carlos Martínez Jaén

Resumen

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Agradecimientos

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Índice general

1	Introducción, motivación y objetivos	1
1.1	Contexto	1
1.2	Motivación	2
1.3	Objetivos	3
1.4	Alcance del proyecto	5
1.5	Competencias desarrolladas	6
1.6	Contribuciones	7
1.7	Estructura del documento	8
2	Antecedentes y estado del arte	11
2.1	Representación de información curricular compleja	11
2.2	Interoperabilidad curricular y sistemas de información de investigación	12
2.3	Formatos de serialización y validación	14
2.3.1	<i>XML</i> y <i>XSD</i>	14
2.3.2	<i>JSON</i> y <i>JSON Schema</i>	15
2.3.3	<i>JSON-LD</i> y <i>YAML</i>	15
2.4	Modelado conceptual y generación de artefactos	17
2.5	Síntesis del estado del arte	18
	Referencia bibliográfica	22

Índice de figuras

Índice de tablas

1.1	Relación entre objetivos específicos y capítulos del documento.	5
2.1	Comparativa de modelos de interoperabilidad curricular relacionados con Open CVN.	13
2.2	Comparativa de formatos de serialización y validación relevantes para Open CVN.	17

Índice de algoritmos

Índice de listados de código

1. Introducción, motivación y objetivos

El presente capítulo introduce el contexto general en el que se enmarca este Trabajo Fin de Grado, describe la motivación que justifica su desarrollo y delimita los objetivos que guían la solución propuesta. Para ello, en primer lugar se analiza el papel del Currículum Vítae Normalizado (CVN) en la gestión de información académica e investigadora en España. A continuación, se expone la necesidad de disponer de una representación de bajo nivel que facilite el procesamiento automático de los datos curriculares. Finalmente, se establecen el alcance del proyecto, las competencias de Computación trabajadas, las principales contribuciones realizadas y la estructura seguida por el resto del documento.

1.1. Contexto

La actividad académica e investigadora produce una cantidad considerable de información curricular de naturaleza heterogénea. En un mismo currículum pueden aparecer datos relativos a formación, experiencia profesional, publicaciones, proyectos de investigación, contratos, estancias, dirección de trabajos, transferencia, actividad docente y otros méritos que responden a estructuras y criterios de descripción diferentes. Esta información no se utiliza únicamente como documento de presentación personal, sino también como entrada para procesos de evaluación, convocatorias públicas, solicitudes de ayudas, acreditaciones, portales institucionales y sistemas internos de gestión de la investigación. En consecuencia, el valor de un currículum no depende solo de su apariencia final, sino también de la capacidad de los sistemas informáticos para interpretar, validar, reutilizar y transformar los datos que contiene.

En el ámbito español, el Currículum Vítae Normalizado (CVN) constituye una norma de referencia para la presentación de información curricular de investigadores. La Fundación Española para la Ciencia y la Tecnología (FECYT) lo define como una norma estándar que

establece un formato común de presentación de los datos curriculares y facilita la interoperabilidad con bases de datos institucionales [FECYT, 2026]. Esta función normalizadora resulta especialmente relevante en un entorno en el que una misma trayectoria académica puede tener que presentarse ante organismos, plataformas y convocatorias con requisitos distintos. Por ello, CVN representa un punto de partida adecuado para estudiar cómo puede formalizarse la información curricular de forma computable y reutilizable.

No obstante, la existencia de un formato normalizado no elimina por sí misma el coste asociado a la elaboración, el mantenimiento y la adaptación de los currículos. A pesar de disponer de una referencia común, los profesores e investigadores universitarios continúan dedicando un tiempo significativo a actualizar méritos, preparar versiones específicas, adaptar contenidos a formatos concretos o trasladar información entre herramientas. Esta situación se ve agravada cuando el mismo historial debe reutilizarse en contextos diferentes, ya que pequeñas variaciones en la estructura, el nivel de detalle o el formato de salida pueden obligar a realizar tareas manuales repetitivas. Desde esta perspectiva, resulta necesario avanzar hacia herramientas abiertas que automaticen parte del proceso y que permitan gestionar los currículos de manera más sistemática.

El tratamiento computacional de CVN, sin embargo, no puede reducirse a la generación de un documento final ni a la lectura de un único fichero XML. La base del trabajo es la norma CVN y el ecosistema de artefactos que la acompaña; dentro de dicho ecosistema, XML actúa como mecanismo de representación e intercambio de datos. En particular, el paquete oficial analizado en este trabajo incluye esquemas XML/XSD, manuales estructurados, modelos auxiliares y tablas de referencia que describen la estructura de los datos, sus códigos internos y su organización jerárquica. Estos elementos aportan la base formal necesaria para la interoperabilidad, pero también introducen una complejidad que dificulta su uso directo como modelo interno de herramientas abiertas, ligeras y reproducibles. En conjunto, el problema abordado consiste en separar el significado de la información curricular de la forma concreta en que la norma la representa y la serializa en sus artefactos técnicos.

1.2. Motivación

La motivación principal de este proyecto surge de la necesidad de definir una representación de bajo nivel para currículos académicos e investigadores basada en la norma CVN, pero orientada al procesamiento automático de datos. Dicha representación debe permitir que la información curricular pueda almacenarse, validarse, transformarse y exportarse sin depender exclusivamente de la representación XML empleada por CVN ni de la herramienta oficial

asociada. Esta necesidad está directamente relacionada con la posibilidad de desarrollar herramientas abiertas para la creación, actualización y adaptación de currículos, tal y como se plantea en la descripción oficial del Trabajo Fin de Grado.

Desde el punto de vista técnico, el uso directo de los artefactos oficiales de CVN como modelo interno presenta varias dificultades. Los esquemas XSD proporcionan una descripción estructural precisa de la representación XML, pero no siempre expresan de forma explícita la semántica curricular necesaria para construir aplicaciones de alto nivel. Además, parte de la información relevante se encuentra distribuida entre manuales, modelos auxiliares y tablas de referencia, lo que obliga a combinar varias fuentes para interpretar correctamente los campos, códigos y relaciones del dominio. Esta dispersión no invalida la norma CVN ni sus artefactos oficiales, que cumplen una función esencial de interoperabilidad, pero sí condiciona su reutilización como base directa para herramientas de gestión, validación o exportación.

El presente Trabajo Fin de Grado aborda este problema desde una perspectiva de Computación. La cuestión central no consiste únicamente en leer o escribir ficheros, sino en analizar fuentes formales heterogéneas, extraer evidencia estructural y semántica, normalizar metadatos, preservar trazabilidad y generar modelos capaces de representar información curricular compleja. De este modo, el proyecto se sitúa en el ámbito de la formalización y representación computable del conocimiento, con especial atención a la separación entre formato de serialización, modelo conceptual y artefactos de validación.

Como respuesta a esta situación, Open CVN propone una base técnica abierta, extensible y potencialmente colaborativa para representar currículos académicos tomando CVN como referencia. La solución no pretende sustituir la norma oficial, sino construir sobre ella una capa intermedia que facilite el desarrollo de herramientas posteriores. Esta capa debe permitir trabajar con un formato final basado en JSON, adecuado tanto para almacenamiento en archivos de texto como para su integración en bases de datos documentales o aplicaciones de procesamiento. De este modo, la norma CVN y sus artefactos oficiales se mantienen como fuentes de trazabilidad e interoperabilidad, mientras que el formato Open CVN se orienta a facilitar la gestión automatizada y la evolución controlada de los datos curriculares sin quedar limitado a la representación XML ni a la herramienta oficial existente.

1.3. Objetivos

El objetivo general de este Trabajo Fin de Grado es *diseñar e implementar una arquitectura computacional abierta para representar, validar, transformar, almacenar y exportar currículos académicos e investigadores tomando CVN como norma y ecosistema de referen-*

cia, pero evitando que su representación XML o la herramienta oficial asociada condicionen por completo el modelo interno del sistema, con el fin de facilitar el desarrollo de herramientas abiertas para la gestión automatizada de currículos.

Para alcanzar esta meta global se han definido los siguientes objetivos específicos:

1. **Analizar el ecosistema CVN y sus artefactos oficiales.** Este objetivo comprende el estudio de los esquemas XML/XSD, manuales estructurados, modelos auxiliares y tablas de referencia que forman parte del paquete empleado como fuente del proyecto.
2. **Estudiar alternativas de representación y validación de datos curriculares.** Se consideran modelos conceptuales, formatos de serialización y herramientas de generación de modelos con el fin de seleccionar una estrategia adecuada para información curricular compleja.
3. **Generar una capa estructural reproducible a partir de los XSD oficiales.** La generación automática permite obtener artefactos consistentes con la representación XML definida dentro del ecosistema CVN y, al mismo tiempo, separar el código generado de la lógica mantenida manualmente.
4. **Normalizar metadatos procedentes de las fuentes oficiales.** Este objetivo busca unificar la información funcional y técnica asociada a los códigos CVN, reduciendo la dispersión existente entre documentos auxiliares.
5. **Definir reglas semánticas conservadoras y trazables.** Las reglas deben permitir interpretar campos, tipos, tablas de referencia y relaciones sin perder la conexión con las fuentes originales de las que se derivan.
6. **Generar modelos de dominio y artefactos conceptuales.** Estos modelos deben representar la información curricular de forma más próxima al dominio académico que a la estructura concreta de la serialización XML.
7. **Definir un formato Open CVN JSON.** El formato propuesto debe ser validable, extensible y adecuado para intercambio, almacenamiento, colaboración y transformación posterior.
8. **Implementar mecanismos de parseo, validación, almacenamiento y exportación.** Estos mecanismos permiten demostrar que la representación definida puede emplearse en flujos reales de gestión curricular y generación de artefactos de salida.
9. **Diseñar mecanismos de importación deterministas y asistidos por modelos de lenguaje.** El objetivo consiste en incorporar a Open CVN currículos ya existentes en CVN

XML o en CVN PDF, priorizando siempre una vía de extracción determinista y reservando el uso de modelos de lenguaje de gran tamaño (del inglés, *Large Language Models*, en adelante LLM) como alternativa opcional para los casos en que la vía determinista no resulta suficiente. Esta vía asistida debe activarse de forma explícita, mantenerse trazable y quedar sujeta a validación posterior frente al formato Open CVN antes de aceptarse como resultado válido.

10. **Verificar el sistema mediante pruebas reproducibles.** La evaluación se apoya en pruebas automatizadas, comandos documentados y flujos de validación extremo a extremo, con el fin de establecer las garantías reales del sistema desarrollado.

La Tabla 1.1 relaciona estos objetivos con los capítulos principales en los que se desarrollan.

Objetivo	Descripción resumida	Capítulos
OE1	Análisis del ecosistema CVN y sus artefactos oficiales	2, 3
OE2	Estudio de alternativas de representación, modelado y validación	2
OE3	Generación estructural reproducible desde XSD	4, 5
OE4	Normalización de metadatos CVN	5
OE5	Definición de reglas semánticas trazables	3, 5
OE6	Generación de modelos de dominio y artefactos conceptuales	5
OE7	Definición del formato Open CVN JSON	6
OE8	Parser, validador, almacenamiento y exportación	6
OE9	Importación determinista y asistida por LLM	6
OE10	Verificación automatizada y flujos reproducibles	7

Tabla 1.1: Relación entre objetivos específicos y capítulos del documento.

1.4. Alcance del proyecto

El alcance del proyecto se centra en la construcción de una base computacional para trabajar con información curricular estructurada. El trabajo incluye el análisis del paquete oficial CVN empleado como fuente, la generación de bindings estructurales, la normalización de metadatos, la definición de reglas semánticas, la generación de modelos de dominio,

la especificación de un formato JSON propio y la implementación de herramientas de validación, importación, almacenamiento y exportación. Estas tareas se han organizado de forma que cada capa conserve trazabilidad hacia las fuentes originales y pueda verificarse mediante procedimientos reproducibles.

Dentro del alcance se incluye también la importación de currículos ya existentes hacia Open CVN a partir de CVN XML y de CVN PDF. Esta importación se resuelve en primer lugar mediante extracción determinista y solo recurre, de forma opcional y explícitamente autorizada, a modelos de lenguaje (LLM) cuando la vía determinista no permite recuperar información suficiente. El resultado de esta vía asistida no se presenta como una validación semántica completa del currículo importado, sino como una propuesta que debe superar la validación del formato Open CVN y quedar disponible para su revisión antes de considerarse definitiva.

Queda fuera del alcance garantizar una conversión completa y sin pérdida de todos los currículos CVN existentes, ya que dicha garantía requeriría cubrir la totalidad de variantes, casos particulares y restricciones prácticas del ecosistema oficial. Tampoco se pretende sustituir la norma CVN ni la infraestructura proporcionada por FECYT. La propuesta debe entenderse como una capa abierta y reproducible que facilita el tratamiento de datos curriculares cuando se necesita validación, transformación, almacenamiento local o exportación a otros formatos.

La herramienta local desarrollada dentro del proyecto cumple una función demostrativa y operativa. Su finalidad es comprobar que el formato propuesto y las capas de validación pueden utilizarse en flujos de importación, almacenamiento, versionado y exportación. No obstante, la contribución principal del TFG no reside en la interfaz de dicha herramienta, sino en la arquitectura de representación, normalización y transformación que permite construirla.

1.5. Competencias desarrolladas

El desarrollo del proyecto se alinea con competencias propias de la intensificación de Computación. En particular, de acuerdo con la descripción oficial del trabajo, se abordan las siguientes:

- **[CM1]** Capacidad para tener un conocimiento profundo de los principios fundamentales y modelos de la computación y saberlos aplicar para interpretar, seleccionar, valorar, modelar y crear nuevos conceptos, teorías, usos y desarrollos tecnológicos relacionados con la informática.

- **[CM2]** Capacidad para conocer los fundamentos teóricos de los lenguajes de programación y las técnicas de procesamiento léxico, sintáctico y semántico asociadas, y saber aplicarlas para la creación, diseño y procesamiento de lenguajes.
- **[CM5]** Capacidad para adquirir, obtener, formalizar y representar el conocimiento humano en una forma computable para la resolución de problemas mediante un sistema informático en cualquier ámbito de aplicación, particularmente los relacionados con aspectos de computación, percepción y actuación en ambientes o entornos inteligentes.
- **[CM6]** Capacidad para desarrollar y evaluar sistemas interactivos y de presentación de información compleja y su aplicación a la resolución de problemas de diseño de interacción persona-computadora.

Estas competencias se reflejan en el análisis de estructuras oficiales complejas, la formalización de información curricular en modelos computables, la generación automática de artefactos, la definición de reglas de validación, la construcción de una herramienta de gestión y la evaluación técnica del sistema mediante pruebas reproducibles. Su grado de cumplimiento se retomará en el capítulo de conclusiones, una vez presentados el desarrollo y los resultados obtenidos.

1.6. Contribuciones

Las principales contribuciones del trabajo pueden resumirse en los siguientes elementos:

- **Análisis computacional del ecosistema CVN:** se identifican las fuentes estructurales, funcionales y auxiliares necesarias para interpretar la información curricular representada en CVN, así como las restricciones que condicionan su uso automatizado.
- **Arquitectura reproducible por capas:** se separan los bindings generados, la normalización de metadatos, la política semántica, los modelos de dominio, el modelo conceptual, el formato JSON, la validación y la herramienta local, evitando que una única representación concentre todas las responsabilidades del sistema.
- **Trazabilidad entre CVN y Open CVN:** se conserva evidencia sobre códigos, fuentes, rutas y decisiones semánticas, con el fin de que la transformación hacia el nuevo formato mantenga una relación verificable con el estándar original.
- **Formato Open CVN JSON:** se define una representación abierta, validable y extensible orientada al intercambio, almacenamiento y exportación de datos curriculares.

-
- **Herramientas de validación y uso:** se implementan parsers, validadores, almacenamiento local, versionado curricular y exportación a otros formatos, lo que permite comprobar la utilidad práctica de la representación definida.
 - **Importación determinista y asistida por LLM:** se implementan vías de importación desde CVN XML y CVN PDF hacia Open CVN, priorizando la extracción determinista y reservando el uso de modelos de lenguaje de gran tamaño como alternativa opcional, trazable y sujeta a validación posterior para los casos en que la extracción determinista resulta insuficiente.
 - **Verificación automatizada:** se incorporan pruebas y flujos reproducibles para evaluar la consistencia de los artefactos generados y el comportamiento de las capas principales del sistema.

En conjunto, estas contribuciones no deben entenderse como una sustitución del ecosistema CVN, sino como una propuesta complementaria que facilita su tratamiento computacional en contextos donde resultan necesarias la validación formal, la transformación entre formatos y la gestión automatizada de currículos.

1.7. Estructura del documento

El resto del documento se organiza de forma progresiva, desde los antecedentes y el análisis del dominio hasta la implementación, evaluación y discusión de la solución desarrollada:

- **Capítulo 2: Antecedentes y estado del arte.** Presenta el contexto técnico y conceptual necesario para comprender el problema, incluyendo CVN, la interoperabilidad curricular, los modelos relacionados, los formatos de serialización y las alternativas de modelado.
- **Capítulo 3: Análisis del ecosistema CVN y propuesta de solución.** Describe las fuentes oficiales utilizadas, sus limitaciones y la propuesta de arquitectura Open CVN derivada de dicho análisis.
- **Capítulo 4: Metodología, herramientas y arquitectura general.** Explica el proceso técnico seguido, las herramientas empleadas y la organización por capas del sistema.
- **Capítulo 5: Implementación del *pipeline* de generación y normalización.** Detalla la generación estructural, la normalización de metadatos, la política semántica y la generación de modelos y artefactos conceptuales.

- **Capítulo 6: Formato Open CVN, validación y herramienta de gestión.** Presenta el formato JSON propuesto, los parsers, validadores, las vías de importación determinista y asistida por LLM, los mecanismos de almacenamiento local y los flujos de exportación.
- **Capítulo 7: Evaluación, resultados y discusión.** Describe la estrategia de verificación, los resultados obtenidos y las garantías reales que ofrece el sistema desarrollado.
- **Capítulo 8: Conclusiones, competencias y trabajo futuro.** Resume el grado de cumplimiento de los objetivos, relaciona el trabajo con las competencias desarrolladas, recoge las limitaciones identificadas y plantea líneas futuras.

2. Antecedentes y estado del arte

El presente capítulo recoge los antecedentes técnicos que sustentan el trabajo: interoperabilidad de información investigadora, formatos de serialización, mecanismos de validación y técnicas de modelado conceptual. Su finalidad es comparar alternativas y justificar las decisiones tecnológicas que se utilizarán en los capítulos posteriores, sin desarrollar todavía el análisis específico del dominio CVN. Ese análisis se reserva para el capítulo siguiente, donde se estudiarán sus artefactos oficiales, sus limitaciones y la propuesta Open CVN construida a partir de ellos.

2.1. Representación de información curricular compleja

La información curricular académica e investigadora constituye un dominio de datos heterogéneo, con entidades, relaciones, restricciones y niveles de detalle que no encajan bien en una representación plana. Desde una perspectiva computacional, esta circunstancia obliga a diferenciar el modelo conceptual del dominio, la serialización utilizada para intercambiar datos y las herramientas que permiten procesarlos. Esta separación será una idea recurrente en el resto del documento, porque permite razonar sobre el significado de los datos sin confundirlo con el formato concreto en el que se almacenan o transmiten.

En España, CVN proporciona una referencia normalizada para la presentación de información curricular de investigadores y favorece la interoperabilidad con bases de datos institucionales [FECYT, 2026]. En este capítulo se menciona únicamente como punto de conexión con el dominio de aplicación. La descripción de sus fuentes, de su representación técnica y de sus limitaciones se reserva para el capítulo siguiente, con el fin de no anticipar el análisis que corresponde a la propuesta de solución.

2.2. Interoperabilidad curricular y sistemas de información de investigación

La gestión de información curricular no es un problema exclusivo de CVN. En el ámbito académico internacional existen diferentes iniciativas orientadas a mejorar la interoperabilidad entre sistemas de información de investigación. Estos sistemas, conocidos habitualmente como *Current Research Information Systems* (CRIS), integran datos sobre investigadores, organizaciones, proyectos, publicaciones, financiación, resultados científicos y otros elementos relevantes para la actividad investigadora.

La interoperabilidad en este dominio no depende solo de compartir documentos, sino también de poder identificar de forma estable a las personas, organizaciones, resultados y relaciones descritas. ORCID, por ejemplo, proporciona identificadores persistentes para investigadores y mecanismos de conexión entre dichos identificadores, contribuciones y afiliaciones [ORCID, 2026]. En una línea complementaria, RO-Crate propone un enfoque ligero para empaquetar datos de investigación junto con sus metadatos [RO-Crate Community, 2024]. Estas iniciativas no resuelven por sí mismas la representación completa de un currículum CVN, pero muestran la importancia de combinar datos estructurados, metadatos explícitos e identificadores reutilizables.

Uno de los modelos más representativos en este ámbito es CERIF, mantenido por euroCRIS. CERIF se presenta como un formato europeo para la gestión, intercambio y almacenamiento de información de investigación, con especial atención a la interoperabilidad entre sistemas CRIS [euroCRIS, 2026]. Su principal ventaja reside en la riqueza de su modelo, que permite representar entidades, relaciones y dimensiones temporales con un alto grado de precisión. Esta expresividad resulta adecuada para infraestructuras institucionales complejas, aunque también introduce un nivel de abstracción y complejidad que puede ser excesivo cuando el objetivo es definir una representación ligera y directamente procesable de currículos.

Otra aproximación relevante es VIVO, una plataforma orientada a conectar, compartir y descubrir información sobre investigación mediante tecnologías de Web Semántica [VIVO Project, 2026]. Frente a modelos más tabulares o documentales, VIVO se apoya en grafos y ontologías para describir investigadores, publicaciones, organizaciones y relaciones académicas. Esta orientación facilita la publicación de datos enlazados y la integración con vocabularios semánticos, pero exige una infraestructura conceptual y tecnológica más compleja que la requerida por una herramienta local de gestión curricular.

En el contexto español destaca también el proyecto HERCULES y, dentro de él, la

Research Ontology for Hercules (ROH). La red de ontologías HERCULES persigue la representación semántica de información de investigación en el sistema universitario español [Universidad de Murcia, 2026, Proyecto HERCULES, 2026]. Además, parte de su ecosistema se ha relacionado con CVN mediante código y artefactos públicos orientados a la importación de información curricular [Deusto HERCULES, 2026b, Deusto HERCULES, 2026a]. Esta proximidad al dominio español convierte a ROH en una referencia relevante, aunque su orientación ontológica y su dependencia de tecnologías de Web Semántica hacen que no sea la opción más sencilla para el alcance de este trabajo.

La Tabla 2.1 resume estos tres enfoques atendiendo al tipo de representación empleada, su principal fortaleza y la limitación que presenta cada uno frente al objetivo de Open CVN.

Modelo	Enfoque de representación	Fortaleza principal	Limitación frente a Open CVN
CERIF	Modelo europeo orientado a entidades y relaciones para sistemas CRIS	Alta expresividad para relaciones institucionales y dimensiones temporales	Complejidad y coste de adopción elevados para una representación ligera
VIVO	Grafos y ontologías de Web Semántica	Publicación de datos enlazados e integración con vocabularios semánticos	Requiere infraestructura RDF/ontológica no necesaria para el alcance del TFG
ROH	Ontología del ámbito universitario e investigador español (proyecto HERCULES)	Proximidad al dominio CVN español y artefactos de importación ya existentes	Orientación ontológica y dependencia de tecnologías de Web Semántica

Tabla 2.1: Comparativa de modelos de interoperabilidad curricular relacionados con Open CVN.

En conjunto, CERIF, VIVO y ROH muestran que la información investigadora puede modelarse con niveles elevados de riqueza semántica. No obstante, también ponen de manifiesto una tensión habitual entre expresividad e implementabilidad. Cuanto más completo y semánticamente rico es un modelo, mayor suele ser el coste de adopción, mantenimiento, consulta y validación. Para Open CVN, esta observación resulta determinante: el objetivo no es competir con infraestructuras CRIS ni con ontologías de investigación completas, sino definir una representación curricular abierta, validable y suficientemente expresiva para el ámbito del TFG.

2.3. Formatos de serialización y validación

La elección de un formato de serialización condiciona la forma en que los datos se almacenan, intercambian y procesan. Sin embargo, un formato de serialización no equivale por sí mismo a un modelo conceptual. Un mismo dominio puede representarse en XML, JSON, YAML u otros formatos, siempre que exista una definición clara de las entidades, atributos, relaciones y restricciones que deben preservarse. Por ello, en este trabajo los formatos se analizan como mecanismos técnicos, no como la única fuente de significado del sistema.

2.3.1. XML y XSD

Extensible Markup Language (XML) es un lenguaje de marcado definido por el World Wide Web Consortium y ampliamente utilizado para representar documentos y datos estructurados. La recomendación XML 1.0 lo define como un perfil de SGML diseñado para facilitar el intercambio y procesamiento de documentos en la Web, con atención explícita a la interoperabilidad y a la facilidad de implementación de procesadores [World Wide Web Consortium, 2008]. XSD se define, a su vez, como un lenguaje para describir la estructura y restringir el contenido de documentos XML, aunque la propia especificación reconoce que algunas aplicaciones pueden necesitar validaciones adicionales no expresables únicamente mediante el esquema [World Wide Web Consortium, 2012].

La principal ventaja de XML en este contexto es su capacidad para representar estructuras jerárquicas complejas y asociarlas a esquemas de validación robustos. Esto permite comprobar si un documento respeta una estructura determinada y facilita la interoperabilidad entre sistemas que comparten la misma definición. Además, el uso de XSD proporciona una fuente formal a partir de la cual pueden generarse artefactos estructurales, como clases de datos o bindings de acceso programático.

No obstante, XML también presenta limitaciones cuando se utiliza como base directa de una herramienta de gestión. Su sintaxis es más verbosa que la de formatos más ligeros, el procesamiento suele requerir bibliotecas específicas y la estructura del documento no siempre coincide con el modelo conceptual más adecuado para una aplicación. Por tanto, XML puede ser una fuente técnica fundamental en sistemas de intercambio estructurado, pero no constituye por sí solo el modelo completo del dominio representado.

2.3.2. JSON y JSON Schema

JavaScript Object Notation (JSON) es un formato ligero de intercambio de datos basado en estructuras de pares clave-valor y listas ordenadas [JSON.org, 2026]. Su sencillez sintáctica, su integración directa con lenguajes de programación y su uso extendido en servicios web lo convierten en una alternativa adecuada para representaciones orientadas al procesamiento automático. En Python, por ejemplo, un documento JSON puede mapearse de forma natural a diccionarios, listas y tipos primitivos, lo que simplifica su manipulación en aplicaciones.

La principal dificultad de JSON es que, por sí solo, no define restricciones estructurales ni semánticas. Para resolver esta limitación se utiliza JSON Schema, un vocabulario que permite describir la estructura esperada de documentos JSON, incluyendo tipos, campos obligatorios, restricciones de valores y composición de objetos. La documentación de JSON Schema lo presenta como un lenguaje declarativo para definir estructura y restricciones de datos JSON, cuya validación requiere comprobar una instancia contra un esquema mediante herramientas específicas [JSON Schema, 2026]. De este modo, JSON puede combinarse con un mecanismo de validación formal similar en propósito a XSD, aunque con una sintaxis más cercana a los formatos habituales de intercambio de datos en aplicaciones modernas.

En el ecosistema Python, Pydantic complementa esta aproximación al permitir definir modelos mediante anotaciones de tipo, validar datos de entrada, serializar estructuras y emitir JSON Schema a partir de los modelos [Pydantic, 2026]. Esta combinación resulta especialmente adecuada para un proyecto que necesita mantener correspondencia entre un formato de intercambio, reglas de validación y objetos manipulables desde código. Al mismo tiempo, obliga a distinguir entre la validación sintáctica o estructural, que puede comprobarse de forma automática, y las reglas semánticas del dominio, que requieren análisis adicional de las fuentes CVN.

Para el contexto de Open CVN, JSON resulta especialmente adecuado como formato final de intercambio y almacenamiento porque permite construir documentos legibles, validables y compatibles con herramientas habituales de desarrollo. Esta elección no implica renunciar a una referencia normativa del dominio. Al contrario, el objetivo consiste en derivar una representación JSON trazable a partir de fuentes oficiales, preservando la relación entre los datos, sus reglas y su interpretación curricular.

2.3.3. JSON-LD y YAML

JSON for Linking Data (JSON-LD) extiende JSON para facilitar la representación de datos enlazados mediante contextos semánticos. La recomendación JSON-LD 1.1 lo de-

fine como una serialización basada en JSON para *Linked Data*, pensada para integrarse con sistemas que ya utilizan JSON y facilitar un camino de evolución hacia datos enlazados [World Wide Web Consortium, 2020]. Su principal aportación consiste en permitir que un documento JSON pueda interpretarse también como parte de un grafo de conocimiento, asociando claves del documento con identificadores semánticos. Esta característica lo convierte en una opción interesante cuando se busca compatibilidad con tecnologías RDF u ontologías.

Sin embargo, la incorporación de semántica enlazada también aumenta la complejidad del sistema. Para un proyecto cuyo objetivo principal es definir una representación curricular abierta, validable y manejable mediante herramientas Python, JSON-LD puede resultar más expresivo de lo necesario en una primera aproximación. Su interés se mantiene como posible línea de evolución futura, en especial si Open CVN necesitara integrarse con ontologías como ROH o con infraestructuras de datos enlazados.

YAML, por su parte, es un formato orientado a la legibilidad humana y empleado con frecuencia en configuración y definición de esquemas [YAML.org, 2026]. Su sintaxis compacta facilita la lectura manual, aunque puede introducir ambigüedades y requiere parsers específicos. En el contexto de este trabajo, YAML resulta relevante principalmente por su uso en herramientas de modelado como LinkML, pero no se adopta como formato final de intercambio curricular.

La Tabla 2.2 recoge, a modo de síntesis, la función principal, el mecanismo de validación asociado y el papel que cada uno de estos formatos desempeña dentro de Open CVN.

Formato	Función principal	Validación asociada	Papel en Open CVN
XML + XSD	Representación jerárquica de documentos y datos estructurados	Esquema XSD	Fuente estructural oficial de CVN; no se adopta como formato final de intercambio
JSON + JSON Schema	Intercambio ligero de datos orientado a aplicaciones	JSON Schema, con apoyo de Pydantic en Python	Formato final de intercambio, almacenamiento y validación de Open CVN
JSON-LD	Extensión de JSON para datos enlazados semánticamente	Contextos JSON-LD y vocabularios semánticos	Línea de evolución futura; no se adopta en la versión actual
YAML	Formato legible orientado a configuración y definición de esquemas	Depende de la herramienta que lo consume (por ejemplo, LinkML)	Referencia en herramientas de modelado; no se emplea como formato de intercambio final

Tabla 2.2: Comparativa de formatos de serialización y validación relevantes para Open CVN.

2.4. Modelado conceptual y generación de artefactos

La separación entre modelo conceptual y formato de serialización conduce a la necesidad de utilizar técnicas de modelado que permitan describir el dominio de forma independiente de una tecnología concreta. En este sentido, Unified Modeling Language (UML) constituye una referencia ampliamente utilizada para especificar, visualizar y documentar sistemas mediante clases, atributos, relaciones, jerarquías y multiplicidades [Object Management Group, 2026b]. Su utilidad en este trabajo reside en la posibilidad de representar conceptos curriculares y sus relaciones sin depender inicialmente de XML, JSON u otro formato de intercambio.

Por este motivo, UML se utilizará como notación principal para representar el esquema conceptual derivado del análisis del dominio. En particular, los diagramas de clases permiten expresar entidades curriculares, atributos, asociaciones y multiplicidades en un nivel intermedio entre la descripción normativa de CVN y los artefactos técnicos generados posteriormente. Esta representación no sustituye a los modelos ejecutables ni a los esquemas de validación, pero proporciona una vista comprensible y tecnológicamente independiente del esquema que se desea obtener.

Cuando el modelo requiere restricciones más precisas que las expresables mediante clases

y relaciones, Object Constraint Language (OCL) permite definir condiciones formales sobre modelos UML [Object Management Group, 2026a]. Estas restricciones pueden utilizarse para especificar reglas de validez, cardinalidad o consistencia que no siempre quedan reflejadas de forma natural en un diagrama estructural. Aunque este trabajo no se basa exclusivamente en UML/OCL como fuente de generación final, estos conceptos resultan relevantes para justificar la separación entre estructura, semántica y validación.

En esta línea, existen herramientas que permiten generar artefactos técnicos a partir de modelos. BESSER, por ejemplo, proporciona un generador de modelos Pydantic a partir de especificaciones de modelado [BESSER, 2026]. Este tipo de enfoque muestra una tendencia importante: definir el dominio en un nivel conceptual o declarativo y obtener después clases, validadores o esquemas de forma automática. La arquitectura de Open CVN adopta esta idea general de generación y trazabilidad, aunque la adapta a las fuentes disponibles en el ecosistema CVN y a las necesidades concretas del proyecto.

Otra herramienta relacionada es LinkML, un lenguaje de modelado orientado a datos estructurados que permite definir esquemas de forma declarativa y generar artefactos en distintos formatos [LinkML, 2026]. LinkML resulta especialmente interesante por su capacidad para actuar como puente entre modelos, esquemas JSON, documentación y tecnologías de datos enlazados. No obstante, para el alcance de este TFG, su adopción completa introduciría una capa adicional de complejidad que no resulta imprescindible. Por ello, se considera como referencia conceptual, pero no como dependencia central de la solución desarrollada.

2.5. Síntesis del estado del arte

El análisis realizado permite extraer varias conclusiones relevantes para el desarrollo de una representación curricular abierta. En primer lugar, los modelos relacionados con información de investigación, como CERIF, VIVO o ROH, muestran soluciones expresivas y semánticamente ricas, aunque su complejidad puede resultar desproporcionada para una herramienta abierta y ligera de gestión curricular. En segundo lugar, los formatos de serialización deben entenderse como mecanismos de intercambio y almacenamiento, no como sustitutos del modelo conceptual. En tercer lugar, UML ofrece una notación adecuada para representar el esquema conceptual de forma comprensible antes de materializarlo en modelos ejecutables o esquemas de validación.

Estas observaciones justifican la necesidad de una arquitectura propia que separe modelo conceptual, serialización y validación, preserve trazabilidad hacia las fuentes oficiales del dominio y genere una representación final más adecuada para validación, almacenamiento y

exportación. De este modo, el estado del arte no conduce a adoptar sin modificaciones una ontología completa ni a reproducir directamente una estructura de intercambio existente, sino a proponer una solución intermedia: suficientemente formal para ser validable, suficientemente trazable para conservar el significado curricular y suficientemente ligera para servir como base de herramientas abiertas.

Referencia bibliográfica

- [BESSER, 2026] BESSER (2026). Pydantic generator - BESSER documentation. <https://besser.readthedocs.io/en/latest/generators/pydantic.html>. Accedido: 2026-02-25.
- [Deusto HERCULES, 2026a] Deusto HERCULES (2026a). CVN. <https://github.com/deustohercules/CVN>. Accedido: 2026-02-16.
- [Deusto HERCULES, 2026b] Deusto HERCULES (2026b). ROH-1. <https://github.com/deustohercules/ROH-1>. Accedido: 2026-02-16.
- [euroCRIS, 2026] euroCRIS (2026). Main features of CERIF. <https://eurocris.org/services/main-features-cerif>. Accedido: 2026-02-16.
- [FECYT, 2026] FECYT (2026). Norma CVN. <https://cvn.fecyt.es/>. Accedido: 2026-02-16.
- [JSON Schema, 2026] JSON Schema (2026). What is JSON Schema? <https://json-schema.org/overview/what-is-jsonschema>. Accedido: 2026-07-22.
- [JSON.org, 2026] JSON.org (2026). Introduccion a JSON. <https://json.org/json-es.html>. Accedido: 2026-02-19.
- [LinkML, 2026] LinkML (2026). Linked data modeling language (LinkML). <https://linkml.io/>. Accedido: 2026-02-23.
- [Object Management Group, 2026a] Object Management Group (2026a). Object constraint language (OCL). <https://www.omg.org/spec/OCL/>. Accedido: 2026-02-25.

-
- [Object Management Group, 2026b] Object Management Group (2026b). Unified modeling language (UML). <https://www.omg.org/uml/>. Accedido: 2026-02-25.
- [ORCID, 2026] ORCID (2026). About ORCID. <https://info.orcid.org/what-is-orcid/>. Accedido: 2026-07-22.
- [Proyecto HERCULES, 2026] Proyecto HERCULES (2026). Research ontology for hercules (ROH). <https://deustohercules.github.io/roh/roh/index.html>. Accedido: 2026-02-16.
- [Pydantic, 2026] Pydantic (2026). Pydantic documentation. <https://docs.pydantic.dev/latest/>. Accedido: 2026-07-22.
- [RO-Crate Community, 2024] RO-Crate Community (2024). Research object crate (RO-Crate). <https://www.researchobject.org/ro-crate/>. Accedido: 2026-07-22.
- [Universidad de Murcia, 2026] Universidad de Murcia (2026). Ontologias - proyecto HERCULES. <https://www.um.es/web/hercules/ontologias>. Accedido: 2026-02-16.
- [VIVO Project, 2026] VIVO Project (2026). VIVO: Connect, share, discover. <https://www.vivoweb.org/>. Accedido: 2026-02-16.
- [World Wide Web Consortium, 2008] World Wide Web Consortium (2008). Extensible markup language (XML) 1.0 (fifth edition). <https://www.w3.org/TR/xml/>. W3C Recommendation, accedido: 2026-07-22.
- [World Wide Web Consortium, 2012] World Wide Web Consortium (2012). W3C XML Schema Definition Language (XSD) 1.1 part 1: Structures. <https://www.w3.org/TR/xmlschema11-1/>. W3C Recommendation, accedido: 2026-07-22.
- [World Wide Web Consortium, 2020] World Wide Web Consortium (2020). JSON-LD 1.1: A JSON-based serialization for linked data. <https://www.w3.org/TR/json-ld11/>. W3C Recommendation, accedido: 2026-07-22.
- [YAML.org, 2026] YAML.org (2026). YAML ain't markup language. <https://yaml.org/>. Accedido: 2026-02-23.